



Universidad Politécnica de Madrid

Grado de Ciencia de Datos e Inteligencia Artificial

TimeSeries Imaging

Técnicas para la Representación de Series Temporales
como imágenes

Rubén Cid Costa

Rodrigo Durán Andrés

ruben.cid@alumnos.upm.es rodrigo.duran.andres@alumnos.upm.es

21 de octubre de 2023

Índice

1. Introducción	2
2. Datos de Meteostat	3
2.1. Análisis del dominio	3
2.1.1. Descripción del conjunto de datos	3
2.1.2. Variable: Temperatura mínima	5
2.1.3. Variable: Temperatura Máxima	6
2.1.4. Variable: Presión	8
2.1.5. Variable: Precipitación	9
2.1.6. Relaciones entre Variables	10
2.2. Proprocesamiento General	11
3. Metodología del proyecto	12
3.1. Redes Neuronales	12
3.2. Capas LSTM	13
3.3. Campo Angular Gramiano	13
4. Experimentos y Resultados	15
5. Conclusiones	16
Referencia	17

1. Introducción

La predicción de la lluvia ha sido fundamental durante siglos para la gestión de las cosechas, del transporte, el turismo y de otros sectores. La lluvia puede también afectar a vida cotidiana de la gente. La predicción precisa del clima proporciona información esencial que impacta en vida de muchas personas.

En este proyecto, nos enfocamos en el estudio de las precipitaciones en Madrid y predicción del clima en el futuro. Se usarán técnicas de Deep Learning para la fase de predicción como **LSTM**, Redes Convolucionales(**CONV**) e incluso, representación de series temporales como imágenes.

2. Datos de Meteostat

El conjunto de datos para el proyecto fueron tomados de Meteostat («Meteostat - Weather Data API», [s.f.](#)), un registro y vendedor de datos meteorológicos a nivel mundial. En concreto, se han tomado los valores de Madrid desde 1940 a 2022. No obstante, por temas de preprocesado solamente se han tomado a partir de 2006.

Hay las siguientes variables: la temperatura mínima, temperatura máxima, temperatura media, presión atmosférica y puntualmente también la dirección y fuerza del viento. Hemos considerado que el viento no era útil ya que al modelo no se le proveería con datos de las estaciones cercanas.

2.1. Análisis del dominio

Los datos meteorológicos como la temperatura y presión son por naturaleza periódicos dado que se ven reflejados por la estación y por el mes del año.

2.1.1. Descripción del conjunto de datos

En el presente trabajo, se utilizan datos climáticos recopilados desde 2006 hasta el 31 de diciembre de 2022. Estos datos incluyen mediciones de temperatura mínima (t_{min}), temperatura máxima (t_{max}), precipitación ($prcp$), y presión atmosférica ($pres$). Estas variables son fundamentales para comprender las condiciones climáticas diarias y estacionales.

Hemos considerado que el viento no era útil ya que al modelo no se le proveería con datos de las estaciones cercanas.

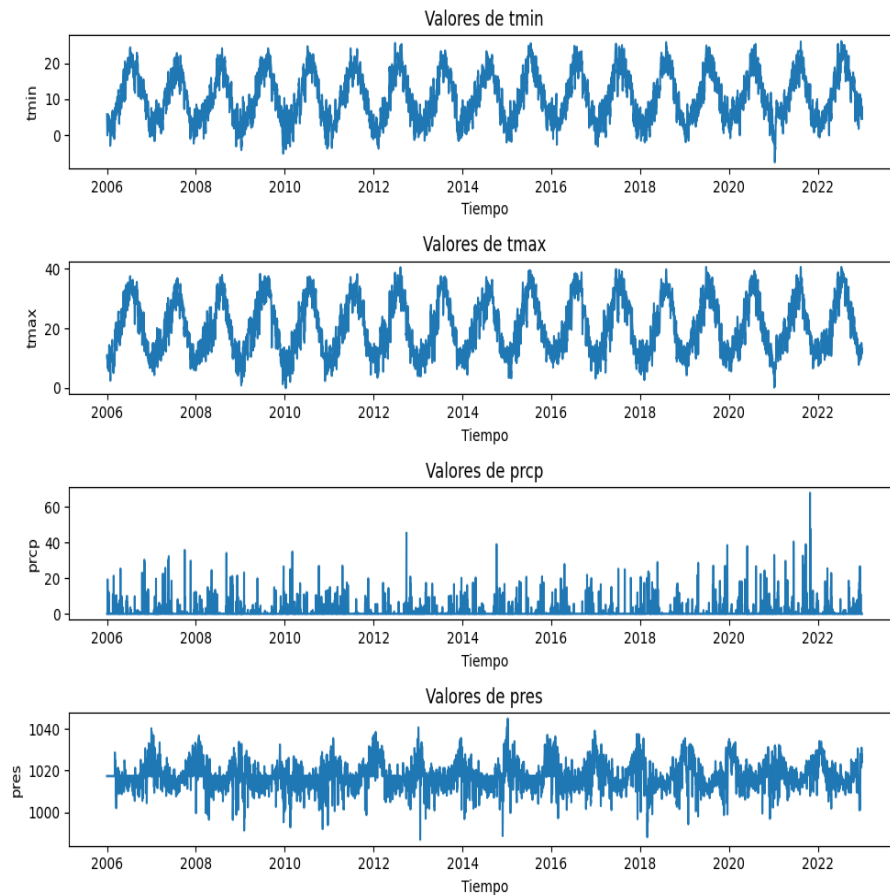


Figura 1: Series Temporales de Todas las Variables Disponibles

Si comparamos a nivel de año, la distribución de la temperatura y las precipitaciones se puede ver como la temperatura sube para los días de verano y reduce el número de precipitaciones. En cambio, para meses más fríos llueve más. Además, se observa que si la temperatura máxima corresponde con la mínima o es menor a la media de ese día en otros años, se incrementan las posibilidades de llover.

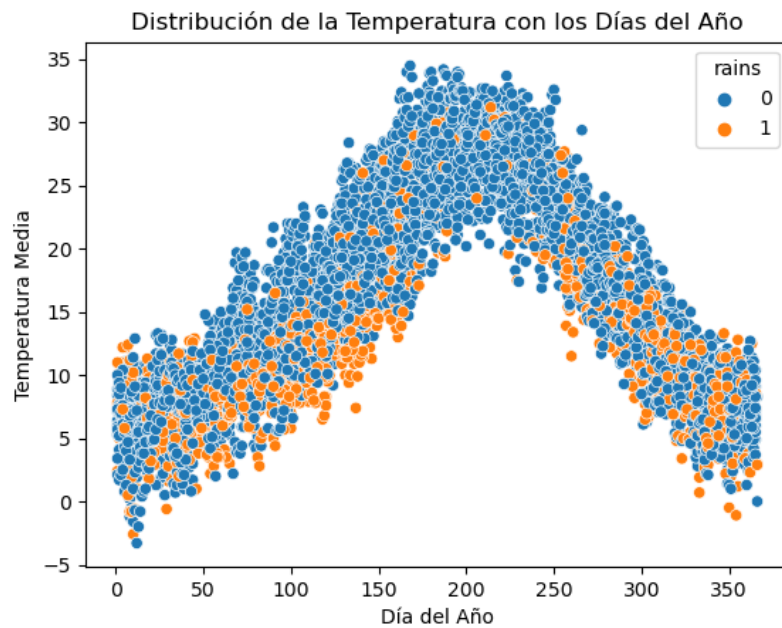


Figura 2: Relación Temperatura Media, Día del Año y Precipitaciones.

2.1.2. Variable: Temperatura mínima

Tiene un ciclo de un año, similar al cos, teniendo una amplitud de 10; una tendencia ligeramente alcista, aunque con un pico en 2006 que justifica entre 9.5 y 12; por último, un ruido de entre 10 y -10.

La suma de estas 3 series da la serie original.

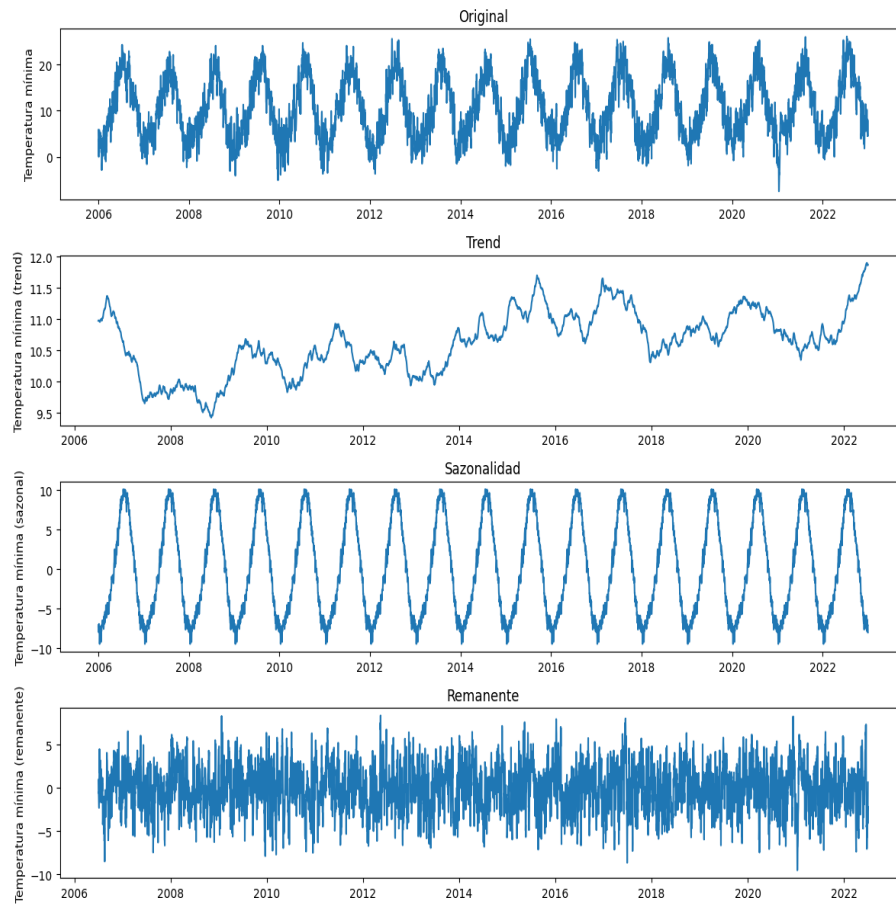


Figura 3: Descomposición de tmin

2.1.3. Variable: Temperatura Máxima

Como es de esperar es muy similar a la temperatura mínima. Tiene un ciclo de un año, similar al cos, teniendo una amplitud de 15; una tendencia que justifica entre 19 y 22 & un ruido de entre 10 y -10. Para muchos

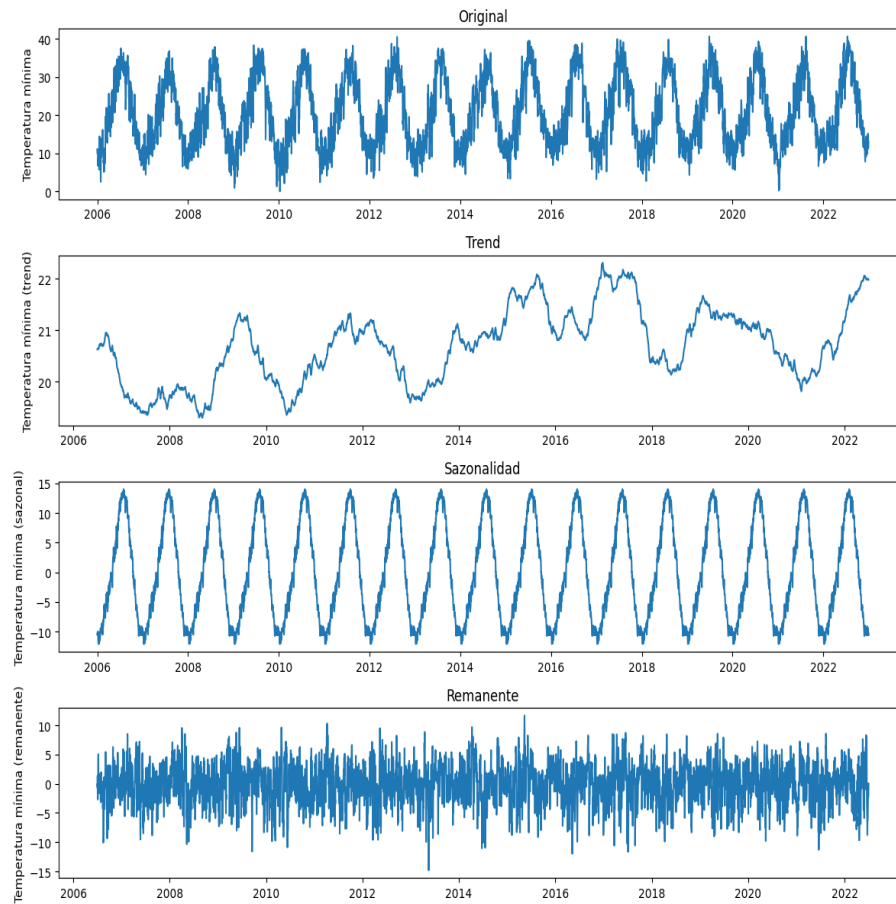


Figura 4: Descomposición de tmax

Si comparamos a nivel de año, la distribución de la temperatura y las precipitaciones se puede ver como la temperatura sube para los días de verano y reduce el número de precipitaciones. En cambio, para meses más fríos llueve más. Además, se observa que si la temperatura máxima corresponde con la mínima o es menor a la media de ese día en otros años, se incrementan las posibilidades de llover.




Figura 5: Relación Temperatura Máxima, Día del Año y Precipitaciones.

2.1.4. Variable: Presión

Esta también tiene un ciclo anual, pero aquí el ciclo justifica entre 10 y -5 mientras que el ruido entre 20 y -30, por tanto, esto muestra que es mas aleatoria.

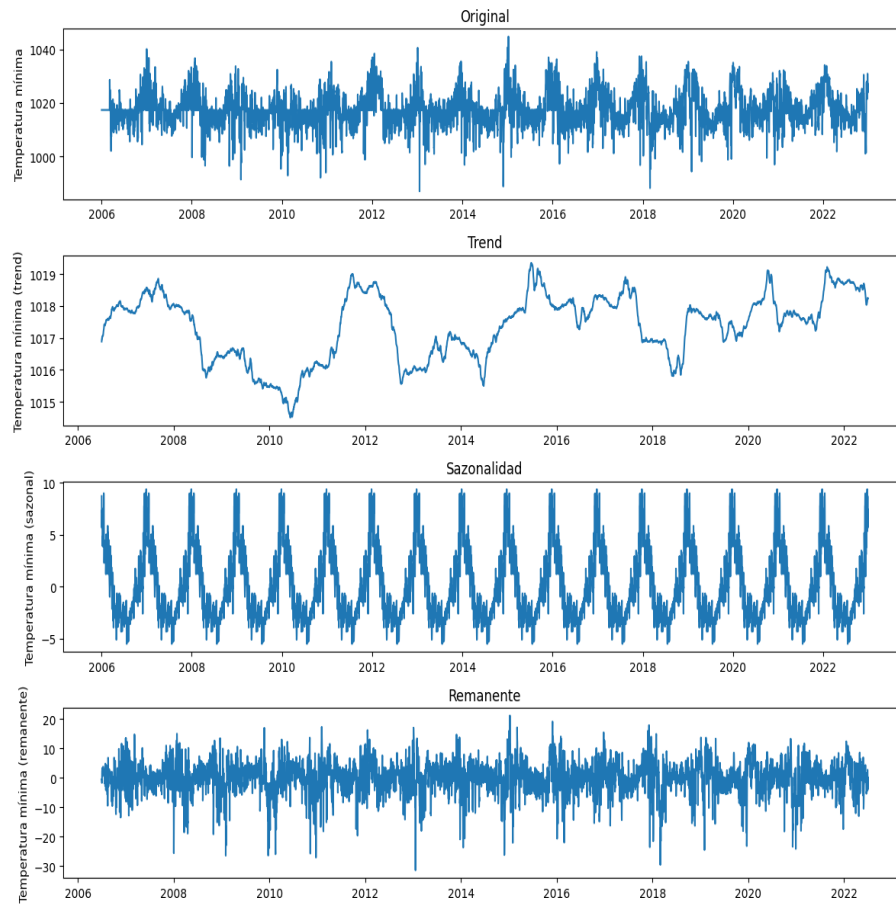


Figura 6: Descomposición de Presión

2.1.5. Variable: Precipitación

Mantiene un patrón anual, pero este solo justifica entre -1 y 6. Mientras que el ruido entre -5 y 60. Esto hace que sea difícil de predecir comparado con las series anteriores.



Figura 7: Descomposición de prcp

2.1.6. Relaciones entre Variables

Un punto importante para el estudio de la relación entre variables. La relación entre las diferentes medidas de temperatura es clara. No obstante, se puede considerar el estudio de la correlación (visual) entre temperatura y presión.

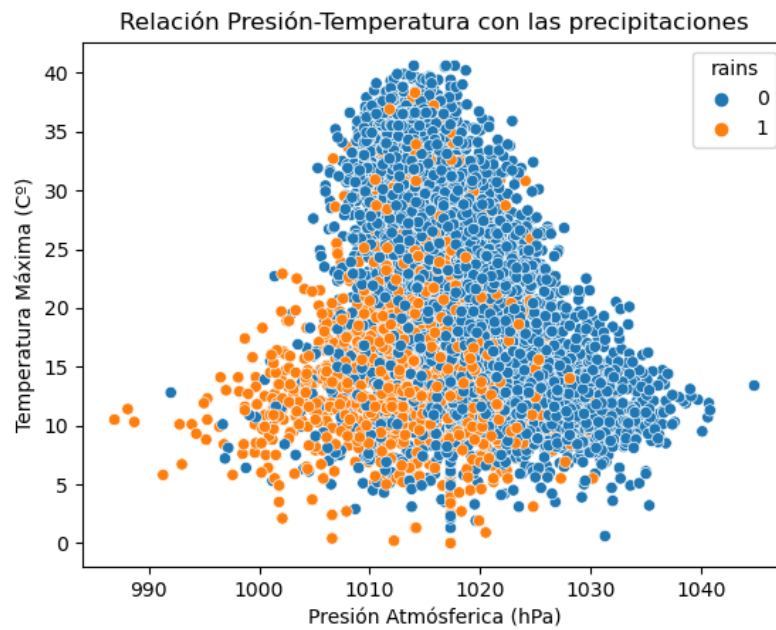


Figura 8: Relación Temperatura-Presión

Se puede ver que para valores bajos de temperatura máxima y presión baja, llueve más a menudo comparado con valores más promedio.

2.2. Proprocesamiento General

La columna `pres` es la única con nulos teniendo 747 de 6209, o sea, un 12 %, decidimos imputarlos con la media.

Como nuestras clases están desbalanceadas, ya que en Madrid llueve menos de la mitad de los días. Hemos hecho undersampling para así en la fase de entrenamiento tener las clases equilibradas.

3. Metodología del proyecto

Como objetivo de este proyecto, se considera la predicción si llueve o no a un horizonte de predicción de un día. De esta forma, se podría avisar a la población para prepararse si se esperan lluvias. En base a los datos disponibles, se considera que llueve las precipitaciones durante un día superan un umbral del $0,1mm/da$ (en base al umbral definido en Iza, 2023).

Para la predicción, se han considerados dos enfoques. El primero aplicaría una red convolucional con capas de LSTM (Long Short Term Memory) sobre una ventana de la serie temporal con todas las variables.

3.1. Redes Neuronales

Una red convolucional (CNN) constituye una arquitectura especializada de redes neuronales profundas diseñada específicamente para el análisis de datos estructurados en forma de cuadrícula, siendo su aplicación más prominente en el procesamiento de imágenes. Su característica distintiva radica en la inclusión de capas convolucionales, las cuales aplican operaciones de convolución para identificar patrones locales en regiones específicas de la entrada. A menudo, estas capas se combinan con capas de agrupación, encargadas de reducir la dimensionalidad y preservar características cruciales.

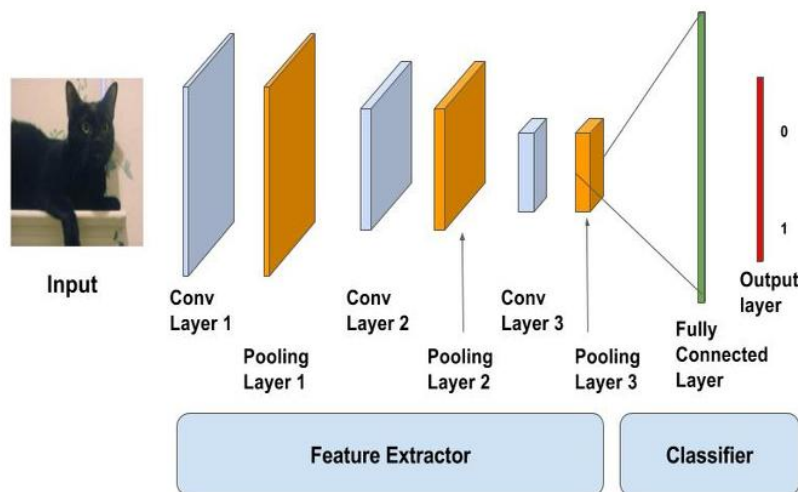


Figura 9: Arquitectura Conv-Net.

<https://keepcoding.io/blog/arquitectura-tipica-red-neuronal-convolucional/>

Las CNN son altamente eficaces en la identificación de patrones espaciales y la construcción de jerarquías de características en datos visuales, destacándose en tareas como la clasificación de imágenes, la segmentación semántica y el reconocimiento de objetos. Su capacidad para aprender representaciones jerárquicas y su invarianza a traslaciones las convierten en una herramienta esencial en el ámbito del procesamiento de imágenes y, de manera más amplia, en los dominios

de la inteligencia artificial y el aprendizaje profundo

3.2. Capas LSTM

Una red neuronal de memoria a largo plazo (LSTM) es una versión avanzada de las redes recurrentes, especialmente diseñada para modelar secuencias temporales y capturar dependencias a largo plazo entre los datos. A diferencia de las redes recurrentes convencionales, las LSTM incorporan celdas de memoria y mecanismos de puertas para regular el flujo de información a lo largo de la secuencia.

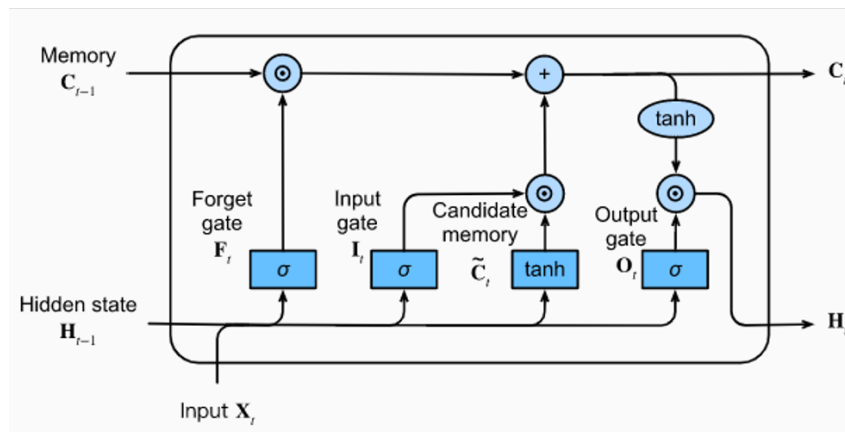


Figura 10: Capa LSTM

<https://medium.com/@ottaviocalzone/an-intuitive-explanation-of-lstm-a035eb6ab42c>

Estas celdas y puertas permiten a las LSTM recordar y olvidar información de manera selectiva, lo que las hace excepcionalmente eficientes en la captura de patrones complejos en datos temporales. Su aplicación es crucial en tareas como la predicción de series temporales y el procesamiento de lenguaje natural, donde las relaciones a largo plazo son esenciales.

3.3. Campo Angular Gramiano

El concepto consiste en crear una matriz que conserve la dependencia temporal. Esta pensado para poder representar una serie temporal como imagen para su uso en CNN.

Consiste en transformar los datos en ángulos, para ello primero los normaliza entre -1 y 1, para así poder aplicar el \arccos . Con esta serie de ángulos, con cada pareja de ángulos posibles, crea una matriz con el coseno de la suma y la resta de dichos ángulos.

$$G = \begin{bmatrix} \cos(\phi_1 + \phi_1) & \cdots & \cos(\phi_1 + \phi_n) \\ \cos(\phi_2 + \phi_1) & \cdots & \cos(\phi_2 + \phi_n) \\ \vdots & \ddots & \vdots \\ \cos(\phi_n + \phi_1) & \cdots & \cos(\phi_n + \phi_n) \end{bmatrix} \quad (1)$$

Tiene que ser escalado, su tamaño crece rápidamente n^2 , aunque hay técnicas para reducir dicho tamaño manteniendo la pendiente (ej.: Piecewise Aggregation Approximation). Esta representación es fácilmente aplicable sobre series temporales otorgando una manera sencilla y eficaz de representarlas. Eckmann et al., 1987

4. Experimentos y Resultados

Tras aplicar las técnicas previas se obtiene los siguientes resultados:

Modelo	Accuracy	Precision	Recall
Conv + TimeSeries Imaging	0.54	0.51	0.51
CONV + LSTM	0.70	0.66	0.63

Cuadro 1: Tabla Resultados

En base a estos resultados, el mejor modelos obtenido es una red convolucional con capas LSTM que opera sobre ventanas de 7 días (una semana) de valores. Aunque los resultados no son buenos y en el futuro, se podría investigar más y probar otros métodos para mejorar los resultados

5. Conclusiones

En conclusión, los experimentos realizados revelan que el modelo basado en una red convolucional con capas LSTM, operando sobre ventanas de 7 días de valores meteorológicos, demuestra ser más efectivo en comparación con la alternativa que utiliza convoluciones y transformación de series temporales (Conv + TS Imaging). Aunque los resultados obtenidos indican una mejora en la precisión, representada por un valor de 0.70, junto con precisiones y recalls respetables, aún queda margen para optimizar el rendimiento del modelo.

Se recomienda una investigación futura para explorar enfoques adicionales y ajustar parámetros con el fin de mejorar la capacidad predictiva y la robustez del modelo en la predicción de patrones meteorológicos en la región de Madrid.

Referencias

- Eckmann, J.-P., Kamphorst, S. O., & Ruelle, D. (1987). Recurrence Plots of Dynamical Systems. *Europhysics Letters*, 4(9), 973. <https://doi.org/10.1209/0295-5075/4/9/004>
- Iza, M. (2023, noviembre). Precipitación: ¿Cuándo es Poco y Cuándo Es Mucho? <https://www.eltiempo.es/noticias/precipitacion-cuando-es-poco-y-cuando-es-mucho>
- Meteostat - Weather Data API [Accessed: 2023]. (s.f.).